



Kauno technologijos universitetas

Informatikos fakultetas

Modulis „Tiriamasis projektas 1“
Projektas: Streso ir nuovargio stebėjimo aplikacija,
naudojanti biologinius signalus iš nešiojamų prietaisų
Projektavimo metodologijos ir technologijų analizė

IFM 4/2 gr. Tautvydas Juškys

Studentas

Doc. Eglė Butkevičiūtė

Projekto vadovas

Doc. Eglė Butkevičiūtė

Dėstytoja

Kaunas, 2024

Turiny

Lentelių sąrašas	3
Santrumpų ir terminų sąrašas	4
Įvadas.....	5
1. Tikslas.....	6
2. Srities apžvalga	7
3. Atrinkti matematiniai metodai , technologijos, sprendimai ir /ar programiniai analogai	11
4. Egzistuojančių rinkoje metodų, programų sistemų savybių kiekybinis ir/ arba kokybinis palyginimas	13
5. Įgyvendinimo problemos.....	14
Išvados	15
Literatūros sąrašas	16

Lentelių sąrašas

1 lentelė. Egzistuojančių rinkoje įrenginių palyginimas	13
--	----

Santrumpų ir terminų sąrašas

Santrumpos:

ŠRK(angl. HRV – Heart Rate Variability) – Širdies ritmo kintamumas

EEG(angl. Electroencephalogram) – Elektroencefalograma

ECG(angl. Electrocardiogram) – Elektrokardiograma

SpO2(angl. Oxygen Saturation) – Deguonies kiekis kraujyje

EDA(angl. Electrodermal Activity) – Odos elektrinis laidumas

GOA(angl. Galvanic Skin Response) – Galvaninis odos atsakas

fNIRS(angl. Functional Near-Infrared Spectroscopy) – Funkcinė netolimoji infraraudonoji spektroskopija

GNT(angl. Deep Neural Network) – Gilusis neuroninis tinklas

PPG (angl. Photoplethysmography) – Fotopletizmografija

KNT (angl. Convolutional Neural Network) – Konvoliucinis neuroninis tinklas

Terminai:

Elektrokardiograma – tai širdies veiklos diagrama.

Biofeedback – Biologinių signalų grįžtamasis ryšys, naudojamas kūno būsenos kontrolei.

Aptikimo slenkstis – Tai lygis, kurio viršijimas ar pasiekimas aktyvuoja reakciją.

Giluminis mokymasis – Dirbtinio intelekto metodas, kurio pagrindą sudaro neuroninių tinklų struktūros mokymasis.

Neuroninis tinklas – Dirbtinio intelekto modelis, kuris imituoja žmogaus smegenų veiklą ir sprendimų priėmimą.

Mašininis mokymasis – Dirbtinio intelekto sritis, kurio tikslas 0 mokyti kompiuterius atlikti užduotis be tiesioginių nurodymų.

Streso indeksas – Kiekybinis rodiklis, atspindintis žmogaus streso lygį.

Žiedinės funkcijos – Matematinės funkcijos, kurių grafikai yra uždaryti į žiedą arba ciklą.

Biometriniai duomenys – Unikalus biologiniai rodikliai, kurie naudojami asmens identifikavimui arba sveikatos stebėjimui.

Bioindikatoriai – Biologiniai požymiai, naudojami žmogaus sveikatos būklės analizei

Įvadas

Dokumentas yra Programų sistemų inžinerijos magistrantūros disciplinos „Tiriamasis projektas 1“ ataskaita. Dokumento paskirtis apibūdinti tyrimo tikslus, apibendrinti atliktą literatūros analizę, pasirengti projekto reikalavimų specifikavimui, projektavimui, susipažinti su užsakymo taikymo sritimi, pasauliniais pasiekimais taikomojoje srityje.

Šiuolaikinėje visuomenėje stresas ir nuovargis yra tapę esminėmis problemomis, darančiomis didelį poveikį tiek asmeniniam, tiek profesiniam gyvenimui. Pasaulio sveikatos organizacija (PSO) nurodo, kad lėtinis stresas ir su juo susiję psichologiniai bei fiziologiniai veiksniai tampa viena pagrindinių sveikatos problemų priežasčių. Stresas ir nuovargis tiesiogiai siejami su produktyvumo mažėjimu, dėmesio sutrikimais, emocinio stabilumo praradimu ir daugeliu ligų, tokių kaip širdies ir kraujagyslių sutrikimai, rizika.

Pastaraisiais metais didelis dėmesys yra skiriamas technologijoms, kurios padeda stebėti ir valdyti žmogaus sveikatos rodiklius. Biologinių signalų stebėjimo prietaisai, tokie kaip išmanieji laikrodžiai, apyrankės ir dėvimieji sensoriai, leidžia realiuoju laiku rinkti duomenis apie širdies ritmą, miego kokybę, kvėpavimą, odos elektrinį laidumą ir kitus parametrus. Šie duomenys, taikant dirbtinio intelekto ir duomenų analizės metodus, leidžia anksti pastebėti padidėjusio streso ar nuovargio požymius bei pateikti personalizuotas rekomendacijas. Tačiau, nepaisant didelės technologinės pažangos, dar trūksta sistemų, kurios sujungtų biologinių signalų analizę su naudotojui prieinamomis ir intuityviomis valdymo platformomis.

Nors jau egzistuoja įvairūs streso ir nuovargio stebėjimo sprendimai, dauguma jų yra riboti keliais aspektais:

- Vienpusiškumas: Daugelis dėvimųjų įrenginių tik renka duomenis, tačiau nesuteikia aiškios, personalizuotos analizės arba naudotojui įgyvendinamų rekomendacijų.
- Neintegruotumas: Įvairių biologinių signalų integracija ir tarpusavio ryšių analizė (pvz. širdies ritmo, miego kokybės ir streso lygio sąsajos) yra silpnai išplėtotą.
- Naudotojo įtraukimas: Trūksta sistemų, kurios ne tik pateiktų duomenis, bet ir aktyviai įtrauktų naudotoją į savo būsenos valdymą per individualizuotus tikslus ir praktikas.

Tyrimas apima efektyvios, daugialypės biologinių signalų analizės sistemos kūrimą, kuri būtų orientuota ne tik į duomenų stebėjimą, bet ir aktyvų streso bei nuovargio valdymą. Mano tyrimas sieks užpildyti šią spragą, integruojant inovatyvias technologijas su praktiniu naudojimu kasdiniame gyvenime.

Raktiniai žodžiai: Stresas, nuovargis, psichologiniai veiksniai, fiziologiniai veiksniai, technologijos, dėvimi prietaisai, technologijos, miego kokybė, dirbtinis intelektas, duomenų analizė, odos elektrinis laidumas, miego kokybė, personalizacija.

Keywords: Stress, fatigue, psychological factors, physiological factors, technology, wearable devices, sleep quality, artificial intelligence, data analysis, skin conductance, personalization.

1. Tikslas

Šio darbo tikslas yra sukurti sistemą, kuri pagerintų žmonių gebėjimą stebėti ir valdyti savo stresą bei nuovargį, naudojant biologinius signalus iš dėvimų prietaisų. Ši sistema padės naudotojams greičiau ir tiksliau atpažinti savo sveikatos būklės pokyčius, taip pat palengvins sprendimų priėmimą dėl gyveimo būdo korekcijų ar savalaikio medicininės pagalbos ieškojimo.

Tikslui pasiekti iškeltos užduotys:

1. Susipažinti su egzistuojančiomis streso bei nerimo stebėjimo ir valdymo sistemomis.
2. Išanalizuoti nerimo stebėjimo galimybes ir metodus
3. Parinkti labiausiai tinkančius sprendimus kuriamai sistemai
4. Suprojektuoti ir sukurti sistemą, kuri gali stebėti streso bei nerimo lygį ir padėti tai valdyti.

Įgyvendinus šias užduotis pasieksimę tikslą ir turėsime sistemą, gebančią realiu laiku stebėti ir teikti rekomendacijas, kaip valdyti streso ir nerimo lygį.

2. Srities apžvalga

Per pastaruosius dešimtmečius, dėvimosios technologijos ir biologinių signalų analizė tapo vienomis iš svarbiausių tyrimų sričių sveikatos priežiūros ir technologijų sektoriuose. Šie pasiekimai prisideda prie inovatyvių sveikatos stebėjimo sistemų kūrimo, kurios leidžia realiu laiku rinkti duomenis, analizuoti fiziologinius procesus ir teikti personalizuotas rekomendacijas.

2.1. Šiuolaikinio mokslo ir technologijų pasiekimai, susiję su tema

Biologinių signalų stebėjimo technologijos per pastaruosius dešimtmečius reikšmingai pažengė į priekį. Šios technologijos leidžia realiuoju laiku rinkti ir analizuoti duomenis, tokius kaip širdies ritmas, odos galvaninis atsakas (GSR), kvėpavimo dažnis ir elektrokardiogramos (EKG) signalai. Naudojami metodai yra taikomi tiek klinikinėje praktikoje, tiek kasdieninėse naudotojų sveikatos stebėjimo veiklose (Persons, et al., 2021) (Varandas, Lima, Badia, Silva, & Gamboa, 2022)

Dabartiniai tyrimai pabrėžia neinvazinių technologijų, tokių kaip funkcionalioji artima infraraudonoji spektroskopija (fNIRS) ir nešiojamieji EEG įrenginiai, svarbą psichologinio ir fiziologinio nuovargio, streso bei kognityvinio išsekimo stebėjime. Šios technologijos siūlo galimybę naudoti sudėtingus mėšininio mokymosi algoritmus, kurie padeda automatiškai nustatyti ir įvertinti naudotojo būklę įvairiose gyvenimo situacijose (Varandas, Lima, Badia, Silva, & Gamboa, 2022)

Dėvimosios technologijos, tokios kaip išmanieji laikrodžiai, apyrankės ir kiti sensoriai, dabar plačiai naudojamos sveikatos ir gyvenimo kokybės stebėjimui. Pavyzdžiui, įrenginiai, kaip „Biovotion Everion“ gali rinkti įvairius parametrus, įskaitant širdies ritmą, aktyvumo lygį, odos laidumą ir temperatūrą, kurie naudojami nuovargio ar streso įvertinimui realiuoju laiku. Šios technologijos yra ypač naudingos dėl jų galimybės surinkti multimodalinius duomenis ir juos analizuoti dirbtiniu intelektu (Varandas, Lima, Badia, Silva, & Gamboa, 2022)

2.2. Taikomos technologijos, jų veikimo principai ir apribojimai

Šiuolaikiniai nešiojamieji sensoriai yra sukurti remiantis pažangiomis medžiagomis, tokiomis kaip polimerai, anglies nanovamzdeliai ir grafenas, kurie leidžia matuoti signalus net esant sudėtingoms aplinkybėms. Tokie įrenginiai kaip Empatica E4 ar „Fitbit Sense“ yra naudojami psichologinio ir fiziologinio streso matavimui, matuojant širdies ritmo kintamumą (ŠRK) ir odos laidumą (EDA) (Hickey, et al., 2021)

Nors dėvimosios technologijos suteikia platų duomenų spektrą, jų apribojimai apima duomenų triukšmą, tikslumo trūkumą ilgo naudojimo metu ir skirtingą individualų jautrumą sensoriams. Be to, duomenų interpretacija yra sudėtinga dėl įvairių fiziologinių ir aplinkos veiksnių poveikio. (Hickey, et al., 2021)

2.3. Naudojami skaičiavimo metodai

Metodų sąrašas:

1. Gilus neuroninis tinklas (Deep Neural Network, DNN).
2. Atsitiktinių miškų metodas (Random Forest).

2.3.1. Giliojo neuroninio tinklo aprašymas

GNN yra dirbtinio intelekto modelis, kuris imituoja žmogaus smegenų veikimą. Jis sudarytas iš kelių sluoksnių (angl. layers), kurių kiekvienas turi skirtingą paskirtį:

- Įvesties sluoksnis (Input layer): Surenka duomenis iš biologinių signalų (pvz. EKG, ŠRK, GSR)
- Paslėptieji sluoksniai (Hidden layers): Apdoroja informaciją, naudodami aktyvacijos funkcijas, tokias kaip ReLU:

$$f(x) = \max(0, x)$$

(1)

- Išvesties sluoksnis (Output layer): Pateikia prognozę (pvz. streso ar nuovargio lygis)

Pavyzdinis tinklo veikimas pateikiamas pagal formules:

$$\begin{aligned} \mathbf{z}(l) &= \mathbf{W}(l)\mathbf{a}^{(l-1)} + \mathbf{b}(l), \\ \mathbf{a}(l) &= \mathbf{g}(\mathbf{z}(l)), \end{aligned}$$

(2)

Kur:

- $\mathbf{W}(l)$: Sluoksnio l svoriai;
- $\mathbf{a}^{(l-1)}$: Ankstesnio sluoksnio aktyvacijų reikšmės
- $\mathbf{b}(l)$: Šališkumo reikšmė;
- $\mathbf{g}(\mathbf{z}(l))$: Aktyvacijos funkcija (pvz. sigmoidinė, tanh arba ReLU).

GNN dažnai naudojamas EKG signalų klasifikavimui, pavyzdžiui, siekiant nustatyti širdies ritmo sutrikimus arba apskaičiuoti ŠRK (Persons, et al., 2021) (Varandas, Lima, Badia, Silva, & Gamboa, 2022)

2.3.2. Atsitiktinių miškų metodo aprašymas

Atsitiktinių miškų algoritmas yra stebimasis mašininio mokymosi metodas, sudarytas iš daugybės sprendimų medžių (angl. decision trees), kurios veikia kaip balsavimo sistema. Algoritmas atlieka klasifikaciją arba regresiją, analizuodamas biologinius signalus.

Metodo veiksmi:

- Iš pradinio duomenų rinkinio sukuriama atsitiktiniai pogrupiai (angl. bootstrap sampling)
- Kiekvienas pogrupis naudojamas apmokyti atskiram sprendimų medžiui.
- Medžiai priima sprendimus savarankiškai, o galutinė išvestis nustatoma balsavimo būdu.

Matematiškai klasifikacijos formulė:

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_n(x)\}, \quad (3)$$

Kur:

- $T_i(x)$: Individualaus medžio prognozė;
- **mode**: Dažniausiai pasitaikanti reikšmė tarp visų medžių.

Šis metodas yra ypač efektyvus, kai duomenys yra nevienalyčiai arba turi daug triukšmo (Luo, Lee, Clay, Jaggi, & Luca, 2020)

2.3.3. Laiko sekų analizė

Laiko sekų analizė leidžia stebėti biologinių signalų dinaminis pokyčius per tam tikrą laiką, o tai yra esminė streso ir nuovargio valdymo dalis. Naudojami tokie metodai kaip:

- Paslėptieji Markovo modeliai (Hidden Markov Models, HMM): Tinka signalams, kuriuose yra diskretūs būsenų perėjimai
- Autoregresiniai modeliai su slenkamuoju vidurkiu (ARIMA): Tinka nuosekliams signalams, kuriuose nėra staigių pokyčių.

Formulė autoregresiniam modeliui:

$$X_t = c + \phi_1 X(t-1) + \phi_2 X(t-2) + \dots + \phi_p X(t-p) + \epsilon_t, \quad (4)$$

Kur:

- X_t : Signalo reikšmė laiko momentu t ;
- $\phi_1, \phi_2, \dots, \phi_p$: Autoregresijos koeficientai;
- ϵ_t : Klaidos terminas.

Šie metodai yra plačiai naudojami EKG ir ŠRK laiko sekų modeliavimui, siekiant stebėti širdies ritmo pokyčius dėl streso ar fizinio aktyvumo. (Hickey, et al., 2021)

2.3.4. Signalų apdorojimo algoritmai

Signalų apdorojimas yra svarbus etapas, kuris užtikrina duomenų kokybę ir tikslumą. Dažniausiai taikomi algoritmai:

- Filtravimas: Naudojami žemo pralaidumo filtrai, pvz. Butterworth filtras, kad būtų pašalintas triukšmas.
- Frekvencijų analizė: Fourier transformacija taikoma siekiant nustatyti signalų komponentus skirtinguose dažniuose.

Pavyzdžiui, ŠRK analizėje naudojama galios spektrinė analizė, siekiant nustatyti mažos ir didelės dažnių komponentų santykį, kuris koreliuoja su simpatinės ir parasimpatinės nervų sistemos veikla. (Persons, et al., 2021) (Varandas, Lima, Badia, Silva, & Gamboa, 2022)

3. Atrinkti matematiniai metodai , technologijos, sprendimai ir /ar programiniai analogai

3.1. Atrinktų matematinių metodų pagrindimas

3.1.1. Matematiniai modeliai

Neuroniniai tinklai buvo pasirinkti dėl jų gebėjimo analizuoti sudėtingus, netiesinius duomenis, tokius kaip biologiniai signalai (EEG, PPG, EKG). Jie leidžia aptikti paslėptus duomenų modelius ir daryti prognozes, kurios yra itin svarbios personalizuoto streso valdymo ar sveikatos stebėsenos sistemose.

Neuroniniai tinklai pasirinkti dėl šių privalumų:

- Tikslumas: Neuroniniai tinklai gali pasiekti aukštesnį tikslumą nei tradiciniai statistiniai metodai, ypač analizuojant multimodalius signalus.
- Lankstumas: Jie gali būti pritaikyti įvairioms problemoms, tokioms kaip klasifikacija, regresija ir anomalijų aptikimas.
- Mokymosi galimybės: Giliojo mokymosi algoritmai, tokie kaip konvoliuciniai neuroniniai tinklai (KNN), yra tinkami vaizdiniais ar laiko eilučių duomenims apdoroti.

Matematinis pagrindas: Standartinis vieno sluoksnio perceptronas, naudojamas daugelyje tinklų, pagrįstas šiomis formulėmis:

$$y = \sigma(Wx + b)$$

(5)

kur W – svorių matrica, b – poslinkio vektorius, x – įvesties duomenys, o σ – aktyvacijos funkcija.

3.2. Technologijų pasirinkimo pagrindimas

Programėlės įgyvendinimui buvo pasirinktos technologijos .NET ir React Native. Trumpai apie šias technologijas:

- .NET: Ši technologija pasirinkta kaip pagrindinė serverio dalis dėl šių priežasčių:
 - Platformos universalumas: .NET palaiko kelių platformų kūrimą, kas yra būtina sistemoms, kurios gali būti pritaikomos tiek mobiliajai, tiek darbalaukio aplinkai.
 - Plačiai išplėtotą dokumentaciją: galima rasti daugybę naudingos informacijos.
 - Bibliotekų rinką: Palaiko integracijas su mašininio mokymosi įrankiais (pvz. ML.NET)
 - Našumas: Aukštas apdorojimo greitis leidžia efektyviai apdoroti didelius duomenų kiekius realiu laiku.
- React Native: React native pasirinktas naudotojo sąsajai kurti dėl šių privalumų:
 - Kodo pernaudojimas: Tas pats kodas veikia tiek iOS, tiek Android sistemose.
 - Plati bendruomenė: Užtikrina daugybę trečiųjų šalių bibliotekų ir įrankių.
 - Realus laiko atnaujinimai: Leidžia greitai keisti ir pritaikyti dizainą.
 - Pritaikymas išmaniesiems įrenginiams: react native išsiskiria pritaikymu dirbant su išmaniaisiais įrenginiais, tiesioginė prieiga prie įrenginio sekamų metrikų.

Alternatyvos, kurios buvo apsvarstytos:

1. Flutter: Flutter yra alternatyva, tačiau pasirinktas React Native dėl didesnės bibliotekų pasirinkimo ir sąsajos su .NET technologija.

2. Java Spring: Java Spring buvo atmestas, nes .NET geriau palaikjo integracijas su Windows operacine sistema ir siūlo daugiau įrankių signalų apdorojimui.
3. Python su Flask/Django: Python alternatyvos buvo atmestos dėl našumo ir integracijų ribotumo. Reikėtų skirti daugiau laiko kuriant kaikuriuos sprendimus patiems.

3.3. Programiniai analogai

Rinkoje egzistuoja keli sprendimai, kurie gali stebėti paciento streso lygį ir matuoti daugelį biologinių rodiklių:

1. NuCalm: Ši programa naudoja EEG signalus ir audinius bei specializuotus prietaisus streso mažinimui. Jų metodika remiasi individualizuota biofeedback technologija. Stebimas EEG, ŠSD
2. Muse S: Naudoja galvos juostą smegenų signalams matuoti ir meditacijai gerinti. Įrenginys atsižvelgia į ŠSD, kraujo cirkuliaciją ir smegenų veiklą.
3. Fitbit Sense: Tinka sveikatos stebėjimui realiu laiku ir duomenų sinchronizavimui per mobiliąs aplikacijas. Stebiamas ŠSD, smegenų veikla, odos temperatūra, aktyvumo lygis.

4. Egzistuojančių rinkoje metodų, programų sistemų savybių kiekybinis ir/ arba kokybinis palyginimas

1 lentelė. Egzistuojančių rinkoje įrenginių palyginimas

Kriterijus/Programa	Muse S ¹	NuCalm ²	Fitbit Sense ³
Pagrindinė paskirtis	Meditacijos ir miego stebėjimas su smegenų bangų biofeedback	Streso mažinimas ir atsipalaidavimo terapija	Bendras sveikatos ir fizinės būklės stebėjimas
Stebimi rodikliai	EEG, ŠSD, miego kokybė	Binauralinės bangos, mikroelektrinė stimuliacija	ŠSD, EKG, SpO2, odos temperatūra, stresas, miegas, aktyvumas
Baterijos veikimo laikas	Iki 10 valandų	Nėra	Apie 6 dienas
Streso stebėjimas	Taip, naudojant EEG	Taip, naudojant binauralines bangas ir GABA stimuliacija	Taip, naudojant EDA ir ŠSD
Miego stebėjimas	Taip, įskaitant miego fazes ir realaus laiko EEG	Ne, orientuotas į atsipalaidavimą prieš miegą	Taip, miego fazės, kokybė ir SpO2 stebėjimas miego metu.
Širdies ritmo matavimas	Taip, naudojant PPG jutiklius	Ne	Taip, nulat ir ramybės būsenoje
Kvėpavimo stebėjimas	Ne	Ne	Taip, miego ir aktyvumo metu
Odos temperatūra	Ne	Ne	Taip
SpO2 (deguonies kiekis kraujyje)	Ne	Ne	Taip
Smegenų veiklos stebėjimas	Taip, EEG	Ne	Ne

¹ <https://choosemuse.com>

² <https://www.nucalm.com>

³ <https://www.fitbit.com/global/us/products/smartwatches/sense>

5. Įgyvendinimo problemos

Esami įrenginiai, tokie kaip „Fitbit“ ar „Muse“ nors ir suteikia naudingos informacijos apie naudotojo sveikatos būklę, tačiau turi keletą trūkumų, dėl kurių kyla poreikis sukurti sistemą. Viena iš didžiausių problemų, susijusių su šiomis sistemomis, yra ribotas matavimų tikslumas ir pritaikomumas specifiniams naudotojams. Pavyzdžiui „Fitbit“ stebi širdies ritmą, tačiau jo tikslumas gali būti ribotas dėl technologinių apribojimų, tokių kaip optiniai jutikliai, kurie jautrūs aplinkos sąlygoms (Lanquist, 2022). Be to, dažnai šie įrenginiai nesuteikia išsamios ir asmeniškai pritaikytos analizės. Pavyzdžiui, „Muse S“ gali matuoti smegenų veiklą ir miego kokybę, tačiau ji nesuteikia išsamios streso ar nuovargio analizės, o duomenys dažnai lieka pasyvūs, be aktyvių rekomendacijų, kaip tobulinti naudotojo sveikatą.

Kita problema yra prietaisų ir programų integracijos trūkumas. Daugeliu atveju naudotojai turi naudoti kelias programas, kad galėtų pasiekti visus reikiamus duomenis, kas sukelia duomenų dubliavimą, klaidinančius įžvalgų pateikimo būdus ir daug investicijų reikalaujančią įrangą. Pavyzdžiui, prieš tai minėti įrenginiai gali rinkti atskirus duomenis apie širdies ritmą ir miegą, tačiau dažnai nėra efektyvios integracijos tarp šių duomenų, todėl naudotojas nesulaukia visapusiško įvertinimo. Dėl šios priežasties daugelis sistemų nesuteikia naudotojui galimybės įvertinti sveikatos būklės visumos.

Esami sprendimai taip pat dažnai nesuteikia pakankamai personalizacijos galimybių. Pavyzdžiui, „Calm“ ir „NuCalm“ siūlo bendrus sprendimus, tokius kaip meditacija ar streso mažinimas, tačiau jie ne visada atsižvelgia į specifinius naudotojo poreikius, nes trūksta bendresnio vaizdo, kad būtų galima pasiūlyti sprendimą, remiantis individualiais sveikatos duomenimis. Nors šios sistemos gali būti naudingos bendram atsipalaidavimui, jos nepasiūlo gilios ir tikslinės analizės, kuri galėtų padėti naudotojui geriau suprasti ir valdyti savo sveikatos būklę kasdieninėse situacijose.

Įvertinant šias problemas, kuriama sistema siekia suteikti tikslumą ir asmeniškai pritaikytą analizę. Pirmiausia, sistema integruos įvairius biologinius signalus, kaip ŠSD, EEG, EDA, SpO2, odos temperatūrą ir miegą. Sistemizuos juos ir pateiks galimybę naudoti tiksliausius duomenis, analizuojamus naudojant mašininių mokymąsi ir dirbtinį intelektą. Tai leis pasiūlyti personalizuotas rekomendacijas, kurios būtų pritaikytos pagal naudotojo būklę realiuoju laiku, o ne tik bendrąsias sveikatos rekomendacijas ar meditacijos būdus. Be to, sistema siūlys išsamų asmeninio įtraukimo mechanizmą, kuris ne tik rinks duomenis, bet ir aktyviai motyvuos naudotoją siekti sveikatingumo tikslų. Pavyzdžiui, naudodama dinamiškus tikslus ir realiu laiku pateikiamas rekomendacijas, sistema skatins naudotoją gerinti miego kokybę, mažinti stresą ir didinti fizinį aktyvumą, atsižvelgiant į individualią informaciją apie jų sveikatos būklę.

Išvados

1. Buvo atlikta įvairių literatūros šaltinių, susijusių su magistrinio darbo tema, analizė.
2. Gilinantis į kitų autorių darbus pastebėta su kokiomis problemomis gali tekti susidurti: įrenginių duomenų nustatymo ribotas tikslumas ir pritaikymas ir streso ar nerimo nustatymo problema.
3. Taip pat pastebėti algoritmų privalumai: gilusis neuroninis tinklas gali pasiekti aukštą tikslumą turint aukštą panaudojamumą. Puikiai tinka individualizuotų problemų sprendimų siūlymui
4. Pastebėtų problemų sprendimus ir privalumus bus galima pasitelkti savo kuriamoje sistemoje.
5. Pastebėta, kad dauguma šiuolaikinių sistemų nepateikia pakankamai personalizuotų rekomendacijų, nes neįvertina naudotojo individualios sveikatos būklės.
6. Nustatyta, kad yra poreikis kurti sistemas, kurios būtų ne tik sveikatos stebėjimo reikmėms, bet ir aktyviai įtrauktų naudotoją į jo sveikatos valdymą, teikiant personalizuotas rekomendacijas realiu laiku.

Literatūros sąrašas

1. Can, Y. S., Chalabianloo, N., Ekiz, D., & Ersoy, C. (2019). Continuous Stress Detection Using Wearable Sensors in Real Life: Algorithmic Programming Context Case Study. *sensors*, 21.
2. Chen, J., Abbod, M., & Shieh, J.-S. (2021). Pain and Stress Detection Using Wearable Sensors and Devices - A Review. *sensors*, 18.
3. Gholami, M., Napier, C., Patino, A. G., Cuthbert, T. J., & Menon, C. (2020). Fatigue Monitoring in Running Using Flexible Textile Wearable Sensors. *sensors*, 11.
4. Giorgi, A., Ronca, V., Vozzi, A., Sciaraffa, N., Florio, A. d., Tamborra, L., . . . Borghini, G. (2021). Wearable Technologies for Mental Workload, Stress, and Emotional State Assessment during Working-Like Tasks: A Comparison with Laboratory Technologies. *sensors*, 21.
5. Gjoreski, M., Lustrek, M., Gams, M., & Gjoreski, H. (2017). Monitoring stress with a wrist device using context. *Journal of Biomedical Informatics*, 12.
6. Goumopoulos, C., & Stergiopoulos, N. G. (2022). Chapter 12 - Mental stress detection using a wearable device and heart rate variability monitoring. *Cognitive Data Science in Sustainable Computing*, 261-290.
7. Hickey, B. A., Chalmers, T., Newton, P., Lin, C.-T., Sibbritt, D., McLachlan, C. S., . . . Lal, S. (2021). Smart Devices and Wearable Technologies to Detect and. *sensors*, 17.
8. Huang, S., Li, J., Zhang, P., & Zhang, W. (2018). Detection of mental fatigue state with wearable ECG devices. *International Journal of Medical Informatics*, 39-46.
9. Iqbal, T., Simpkin, A. J., Roshan, D., Glynn, N., Killilea, J., Walsh, J., . . . Shahzad, A. (2022). Stress Monitoring Using Wearable Sensors: A Pilot Study and Stress-Predict Dataset. *sensors*, 16.
10. Lanquist, L. (2022). The Fitbit Sense is a Feature-Packed Fitness Tracker That's Easy to Wear All Day. 1.
11. Luo, H., Lee, P.-A., Clay, L., Jaggi, M., & Luca, V. D. (2020). Assessment of Fatigue Using Wearable Sensors: A Pilot Study. *Emerging applications*, 14.
12. Martins, N. R., Annaheim, S., & Rossi, C. M. (2021). Fatigue Monitoring Through Wearables: A State-of-the-Art Review. *frontiers in physiology*, 25.
13. Moshawrab, M., Bouzouane, M. A., Ibrahim, H., & Raad, A. (2022). Smart Wearables for the Detection of Occupational Physical Fatigue: A Literature Review. *sensors*, 25.
14. Pasquale, V. D., Simone, V. D., Radano, M., & Miranda, S. (2022). Wearable devices for health and safety in production systems: a literature review. *IFAC-PapersOnLine*, 341-346.
15. Persons, A. K., Ball, J. E., Freeman, C., Macias, D. M., Simpson, C. L., Smith, B. K., & V., R. F. (2021). Fatigue Testing of Wearable Sensing Technologies: Issues. *materials*, 27.
16. Pimentel, G., Rodrigues, S., Silva, P. A., Vilarinho, A., Vaz, R., & Cunha, J. P. (2019). A wearable approach for intraoperative physiological stress monitoring of multiple cooperative surgeons. *Internaional Journal of Medical Informatics*, 60-68.
17. Sampei, K., Ogawa, M., Torres, C. C., Sato, M., & Miki, N. (2016). Mental Fatigue Monitoring Using A Wearable Transparent Eye Detection System. *michromachines*, 8.

18. Seoane, F., Mohino-Herranz, I., Ferreira, J., Alvarez, L., Buendia, R., Ayllon, D., . . . Gil-Pita, R. (2014). Wearable Biomedical Measurement Systems for Assessment of Mental Stress of Combatants in Real Time. *sensors*, 22.
19. Varandas, R., Lima, R., Badia, S. B., Silva, H., & Gamboa, H. (2022). Automatic Cognitive Fatigue Detection Using Wearable fNIRS and Machine Learning. *sensors*, 14.
20. Wu, J.-Y., Ching, C. T.-S., Wang, H.-M. D., & Liao, L.-D. (2022). Emerging Wearable Biosensor Technologies for Stress Monitoring and Their Real-World Applications. *biosensors*, 20.